

PROPOSAL TSDN 2022



Upaya Peningkatan Produksi Beras melalui Identifikasi Penyakit Padi untuk Menjaga Indeks Ketahanan Pangan Indonesia

RusselbinMitchel

Daftar Isi

Daftar Isi	2
Daftar Gambar	3
Daftar Table	4
1. Pendahuluan (Abstrak)	5
2. Latar Belakang	5
3. Analisa Kebutuhan Data	7
3.1. Global Food Score Index (GFSI)	8
3.2. Luas Lahan Panen Padi	8
3.3. Produksi Beras	9
3.4. Import Beras	9
3.5. Tingkat Konsumsi/Kapita/Tahun	10
3.6. Image Dataset dari Penyakit Tanaman Padi	10
4. Alur Penelitian	11
4.1. Case Understanding	12
4.1.1. GFSI & GFSI Indonesia	12
4.1.2. Korelasi Faktor-Faktor Pangan terhadap GFSI	14
4.1.3. Visualisasi Hubungan faktor-faktor Pangan Terhadap GFSI	15
4.1.4. Serangan OPT Padi terhadap Jumlah Produksi Beras	16
4.2. Data Preprocessing	17
4.2.1. Dataset	17
4.3. Model Training	17
4.3.1. Arsitektur Model	17
4.3.2. Training Model	19
4.4. Model Testing	20
4.5. Web Deployment	22
5. Kesimpulan	24
Referensi	24

Daftar Gambar

Gambar 1 Contoh setiap gambaran daun yang masuk ke kelas: Bintik Coklat, Sehat, Hispa, dan Ledakan Daun	11
Gambar 2 Alur Penelitian	11
Gambar 2 Alur Penelitian	12
Gambar 3 Peta GFSI 2022	13
Gambar 4 Peta GFSI 2022	13
Gambar 5 Score GFSI Indonesia Tahun 2018 – 2022	13
Gambar 6 Dashboard Hubungan Beberapa Faktor Pangan Terhadap GFSI	15
Gambar 7 Perkiraan Kehilangan Hasil Akibat Serangan OPT Utama pada Tanaman Padi [6]	16
Gambar 8 jumlah data di setiap kelas	17
Gambar 9 Sampel gambar daun padi	18
Gambar 10 Arsitektur <i>Model Deep Learning</i> Menggunakan <i>DenseNet121</i> dengan 4 <i>Fully Connected Neural Networks</i>	18
Gambar 11 Grafik model accuracy train dan test terhadap epoch (iterasi ke-)	19
Gambar 12 Grafik model loss train dan validation terhadap epoch (iterasi ke-)	20
Gambar 13 <i>Classification Report Train Test Data</i> .	20
Gambar 14 Contoh beberapa klasifikasi records	21
Gambar 15 Hasil prediksi data test	21
Gambar 16 Contoh klasifikasi menggunakan gambar random google.images.com	22

Daftar Table

Tabel 2 Global Food Score Index Indonesia Tahun 2018 – 2022 [18]	8
Tabel 3 Luas lahan Panen Padi [19]	8
Tabel 4 Produksi Beras [19]	9
Tabel 5 <i>Import</i> Beras [20]	9
Tabel 6 <i>Update Import</i> Beras [20]	10
Tabel 7 Konsumsi Beras/Kapita/Tahun [21]	10
Tabel 8 Korelasi beberapa faktor pangan terhadap GFSI	14

1. Pendahuluan (Abstrak)

Beras merupakan aspek yang penting dalam menjaga indeks ketahanan pangan Indonesia. Produksi dan kualitas beras yang stabil merupakan aspek penting dari ketahanan pangan. Salah satu penyebab yang dapat menurunkan kualitas dan kuantitas produk pertanian yaitu penyakit pada tanaman yang menyerang daun padi. Serangan OPT Utama pada tanaman padi tahun 2020 sebesar 411,874 ha dengan jumlah puso/gagal berjumlah 7474 ha dengan perkiraan total produksi gagal akibat serangan OPT adalah 74,202,795 ton. prediksi dan preskripsi dari permasalahan penurunan produksi akibat serangan penyakit pada tanaman padi dapat meningkatkan kemungkinan klasifikasi penyakit padi yang tepat, sehingga mampu disikapi dengan cara yang tepat untuk menghindari puso (kegagalan panen). Oleh karena itu, pada penelitian ini dikembangkan model *machine learning* dengan kemampuan identifikasi (prediksi) dan solusi atas hasil klasifikasi (*prescriptive*) dengan menggunakan *transfer learning* dengan *pretrained* model *DenseNet121*. *Dataset* training yang digunakan adalah *dataset* kaggle dengan 4 jenis kelas *healthy*, *brown spot*, *hispa*, dan *leaf blast*. Terdapat beberapa tambahan layers neural networks yang bersifat *Fully Connected Layer* yang terdiri dari *Dense Layer* dan *Dropout Layer*. Model yang dihasilkan mampu memberikan f1-score sebesar 100% pada data test dan model dengan sangat baik mampu mengklasifikasikan foto penyakit tanaman padi yang secara acak diambil dari google.images.com.

Kata kunci: Penyakit, Padi, Vision, Transfer Learning, DenseNet12, Klasifikasi

2. Latar Belakang

Indonesia merupakan salah satu penghasil beras terbesar di dunia dimana penduduknya juga menjadikan beras sebagai makanan pokoknya. Produksi dan kualitas beras yang stabil merupakan aspek penting dari ketahanan pangan. Dengan upaya peningkatan produksi beras dan juga mengimpor dari negara lain, Indonesia berupaya menjaga kestabilan harga beras agar tetap terjangkau oleh semua pihak. Pada tahun 2014, Indonesia menjadi produsen beras terbesar dunia setelah China dan India [1]. Namun dalam beberapa tahun terakhir, Indonesia harus mengimpor sekitar 3 juta ton beras setiap tahun terutama dari Thailand dan Vietnam [2]. Produksi beras yang tidak seimbang dapat menimbulkan masalah lain yang lebih serius bahkan mempengaruhi keadaan perekonomian negara [3].

Salah satu penyebab yang dapat menurunkan kualitas dan kuantitas produk pertanian yaitu penyakit pada tanaman yang menyerang daun padi [4]. Penyakit padi dapat disebabkan oleh kondisi cuaca, kondisi tanah, virus, jamur dan hama lainnya [5].

Berdasarkan data yang Direktorat Perlindungan Tanaman Pangan Kementerian Pangan Indonesia pada tahun 2020, serangan OPT Utama pada tanaman padi tahun 2020 sebesar 411,874 ha dengan jumlah puso/gagal berjumlah 7474 ha. Perkiraan total produksi gagal akibat serangan OPT adalah 74,202,795 ton [6]. Penyakit pada padi dapat dikenali dari perubahan fisik pada permukaan daun. Namun, seiring perkembangan gejala, menjadi sulit untuk membedakan penyakit tanaman [7].

Secara umum, ada empat jenis penyakit padi yang ditemukan pada permukaan daun: penggerek batang, penyakit hawar daun, penyakit blas, dan penyakit tungro. Penyakit yang berbeda memerlukan perawatan yang berbeda. Jika terlambat terdeteksi dan tidak dikelola dengan baik, kerugian dapat terjadi berupa gagal panen (puso) dan berkurangnya hasil panen padi itu sendiri. Untuk mengatasi hal tersebut, petani perlu mengembangkan aplikasi yang memungkinkan mereka menggunakan *computer vision* untuk deteksi dini berbagai jenis penyakit yang menyerang padi.

Berdasarkan latar belakang diatas, kami memilih topik penelitian ini untuk dapat memberikan prediksi dan preskripsi dari permasalahan penurunan produksi akibat serangan penyakit pada tanaman padi. Menggunakan *machine learning* yang terintegrasi dengan *computer vision* yang diharapkan dapat meningkatkan hasil prediksi jenis penyakit padi sehingga mampu melakukan aksi yang tepat untuk menghindari puso (kegagalan panen).

Beberapa metode *computer vision* yang digunakan untuk mengidentifikasi penyakit pada tanaman padi adalah metode *neural network*, karena metode ini memiliki ketepatan untuk mengatasi masalah pendeteksian hama dari citra atau kasus klasifikasi [8]. Aplikasi yang dikembangkan untuk mendeteksi penyakit padi adalah dengan menggunakan metode CNN (*convolutional neural network*). CNN (*Convolutional Neural Network*) adalah algoritma pembelajaran mendalam yang biasa dipakai untuk memecahkan masalah klasifikasi citra. Dalam hal pengenalan objek visual, *Convolutional Neural Network* telah menjadi pendekatan *machine learning* yang paling sering digunakan [9] dan mendapat perhatian di bidang pertanian seperti deteksi tanaman, deteksi buah, identifikasi penyakit, deteksi gulma, pengenalan hama, dan lain-lain [10], [11].

Penelitian terkait mengenai identifikasi penyakit tanaman padi menggunakan *Neural Network* telah banyak dilakukan. Penyakit pada tanaman padi biasanya dibagi menjadi 3 jenis yaitu *bacterial leaf blight*, *brown spot*, *leaf smut*. Dalam penelitian Anggiratih, dkk[12] menggunakan pendekatan transfer learning dengan arsitektur *MobileNetV3* dan *EfficientNet B3* dan menggunakan sebanyak 857 gambar penyakit padi yang terklasifikasi menjadi 2 jenis yaitu penyakit *brown spot* dan *bacterial leaf*. Hasil penelitian menunjukkan bahwa arsitektur *EfficientNet B3* memperoleh nilai akurasi yang lebih tinggi yaitu 99%, sedangkan *MobileNet V3* memperoleh akurasi sebesar 79.53%. Penelitian oleh Saputra, dkk [13] dengan arsitektur *MobileNetV1* menggunakan *dataset* UCI sebanyak 120 gambar yang terklasifikasi sebanyak 3 kelas jenis penyakit yaitu *bacterial leaf blight*, *brown spot*, *leaf smut*. Hasil akurasi yang diperoleh adalah sebesar 92% dengan penggunaan *epoch* sebanyak 100. Penelitian yang dilakukan oleh Whidhiasih, dkk [14] dengan menggunakan *Adaptif Neuro Fuzzy Inference System (ANFIS)* dengan *dataset* yang sama pada penelitian Saputra, dkk. Hasil akurasi yang diperoleh sebesar 98.5%.

Penelitian oleh Agustiani, dkk [15] menggunakan ekstraksi fitur *Color Histogram* dan *Random Forest* sebagai *classifier* dan menggunakan sebanyak 120 citra penyakit tanaman padi yang terklasifikasi sebanyak 3 jenis penyakit yaitu *bacterial leaf blight*, *brown spot*, *leaf smut*. Dalam penelitian tersebut dilakukan augmentasi citra untuk menambah jumlah citra asli sehingga total citra pada penelitian ini adalah 2.550. Hasil penelitian memperoleh akurasi sebesar 99.65%. Penelitian oleh Herwina, dkk [16] menggunakan *dataset* dari kaggle sebanyak 1294 gambar dengan skema validasi hold-out validation, dan menggunakan *MobileNetV1* menghasilkan akurasi sebesar 94% dan *MobileNetV2* menghasilkan akurasi sebesar 95%. Model yang telah dilatih selanjutnya diintegrasikan ke dalam aplikasi *Healthy*, *Brown Spot*, *Hispa*, dan *Leaf blast* berbasis Android. Penelitian oleh Sitompul, dkk[17] menggunakan *DenseNet201* dengan jumlah citra yang digunakan sebanyak 3.355 yang diklasifikasikan menjadi 4 kelas yaitu. Hasil penelitian model mendapatkan akurasi sebesar 83%.

3. Analisa Kebutuhan Data

Terdapat dua kelompok data yang digunakan dalam penelitian ini yaitu data analisis tingkat pengaruh indeks ketahanan pangan terhadap beberapa faktor yaitu luas lahan, tingkat produksi, tingkat *import*, dan tingkat konsumsi penduduk per kapita

serta data latih dan test untuk mengenali pola dari penyakit pada tanaman padi. Berikut adalah penjelasan lengkap data yang digunakan pada penelitian ini:

3.1. Global Food Score Index (GFSI)

Tabel 2 Global Food Score Index Indonesia Tahun 2018 – 2022 [18]

Tahun	Global Food Security
	Index
2018	63.6
2019	61.5
2020	61.6
2021	59.8
2022	60.2

GFSI merupakan ukuran tingkat ketahanan pangan pada suatu negara dengan rentang *score* (0-100). *Index* ini diukur berdasarkan 68 ukuran pendorong kualitatif dan kuantitatif ketahanan pangan yang terkelompok menjadi 4 empat pilar utama: keterjangkauan, ketersediaan, kualitas dan keamanan, serta keberlanjutan dan adaptasi pangan. Pada penelitian ini digunakan score GFSI Indonesia pada rentang tahun 2018-2022 untuk dianalisa pengaruh beberapa faktor-faktor pertanian terhadap GFSI.

3.2. Luas Lahan Panen Padi

Tabel 3 Luas lahan Panen Padi [19]

Tahun	Luas Panen (ha)
2018	11377934.44
2019	10677887.15
2020	10657274.96
2021	10411801.22
2022	10606513.22

Penelitian ini menggunakan luas lahan panen padi nasional dalam satuan (ha)

pada rentang tahun 2018-2022. Luas lahan panen padi merupakan salah satu faktor pertanian yang dianalisa pengaruhnya terhadap GFSI.

3.3. Produksi Beras

Tabel 4 Produksi Beras [19]

Tahun	Produksi (ton)
2018	59200533.72
2019	54604033.34
2020	54649202.24
2021	54415294.22
2022	55670219.00

Penelitian ini menggunakan jumlah produksi beras nasional dalam satuan (ton) pada rentang tahun 2018-2022. Jumlah produksi beras merupakan salah satu faktor pertanian yang dianalisa pengaruhnya terhadap GFSI.

3.4. *Import* Beras

Tabel 5 *Import* Beras [20]

Tahun	<i>Import</i> Beras (Ton)
2018	2253824.4
2019	444508.8
2020	356286.2
2021	407741.4
2022	0

Penelitian ini menggunakan jumlah *import* beras nasional dari berbagai negara dalam satuan (ton) pada rentang tahun 2018-2022. *Import* beras merupakan salah satu faktor pertanian yang dianalisa pengaruhnya terhadap GFSI. Nilai *import* beras pada tahun 2022 diprediksi dengan menggunakan seluruh faktor pangan dan *index* GFSI Indonesia menggunakan *multivariable linear regression*, berdasarkan hasil prediksi jumlah *import* beras pada tahun 2022 adalah 998648.6 Ton.

Sehingga *table* tingkat *import* beras di-*update* menjadi

Tabel 6 *Update Import Beras* [20]

Tahun	<i>Import</i> Beras (Ton)
2018	2253824.4
2019	444508.8
2020	356286.2
2021	407741.4
2022	998648.6

3.5. Tingkat Konsumsi/Kapita/Tahun


Tabel 7 Konsumsi Beras/Kapita/Tahun [21]

Tahun	Konsumsi Beras/Kapita/Tahun (kg)
2018	94.47
2019	94.02
2020	100.9
2021	93.65
2022	92.93

Penelitian ini menggunakan tingkat konsumsi beras/kapita/tahun dalam satuan (kg) pada rentang tahun 2018-2022. *Import* beras merupakan salah satu faktor pertanian yang dianalisa pengaruhnya terhadap GFSI.


3.6. *Image Dataset* dari Penyakit Tanaman Padi

Dataset yang digunakan pada penelitian ini adalah [22] *Dataset* ini berisi gambar daun padi untuk 4 kelas yang berbeda: Bintik Coklat, Sehat, Hispa, dan Ledakan Daun. Ini berisi 523 gambar untuk setiap kelas. *Dataset* lain yang juga digunakan sebagai kombinasi adalah *dataset* [23] yang merupakan *augmented dataset* dari daun padi yang telah terinfeksi secara manual ke dalam kelas penyakit. *Dataset* dibuat dengan memisahkan daun yang terinfeksi secara manual ke dalam kelas penyakit : Bintik Coklat, Sehat, Hispa, dan Ledakan Daun. *Dataset* ini telah diverifikasi oleh para petani dan *expert* pada domain terkait.




Gambar 1 Contoh setiap gambaran daun yang masuk ke kelas: Bintik Coklat, Sehat, Hispa, dan Ledakan Daun

4. Alur Penelitian



Gambar 2 Alur Penelitian

Gambaran alur dari penelitian Upaya Peningkatan Produksi Beras melalui Identifikasi Penyakit Padi untuk Menjaga Indeks Ketahanan Pangan Indonesia ditunjukkan dengan pada gambar diatas. Proses alur penelitian dimulai dari pemahaman *case* lalu dilanjutkan dengan pengumpulan *dataset* dan data *understanding*. *Data preparation* dilanjutkan untuk menyesuaikan *dataset* sehingga dapat dilakukan proses *training vision machine learning* dan *deep learning* untuk memprediksi dan memberikan *prescriptive* dari masalah yang dihadapi. Hasil prediksi dan *prescriptive* akan di-*deploy* dengan basis *website*.



Gambar 2 Alur Penelitian

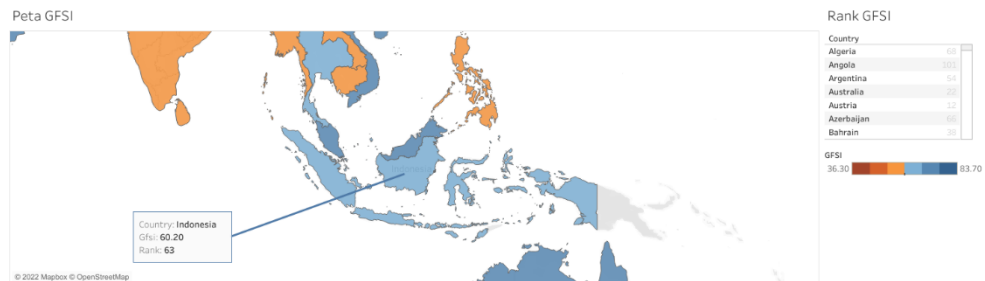
Gambaran alur dari penelitian Upaya Peningkatan Produksi Beras melalui Identifikasi Penyakit Padi untuk Menjaga Indeks Ketahanan Pangan Indonesia ditunjukkan dengan pada gambar diatas. Proses alur penelitian dimulai dari pemahaman *case* lalu dilanjutkan dengan pengumpulan *dataset* dan data *understanding*. *Data preparation* dilanjutkan untuk menyesuaikan *dataset* sehingga dapat dilakukan proses *training vision machine learning* dan *deep learning* untuk memprediksi dan memberikan *prescriptive* dari masalah yang dihadapi. Hasil prediksi dan *prescriptive* akan di-*deploy* dengan basis *website*.

4.1. Case Understanding

4.1.1. GFSI & GFSI Indonesia


Kondisi pangan yang cukup, baik jumlah maupun mutunya, aman, beragam, bergizi, merata, sehingga masyarakatnya dapat hidup dengan sehat dan secara aktif dapat produktif dalam kehidupannya merupakan cerminan ketahanan pangan bagi suatu negara. Salah satu badan yang mengukur tingkat ketahanan pangan suatu negara adalah *Economist Impact* [24]. Badan ini mengukur *index* dari lebih dari 100 negara di dunia berdasarkan berdasarkan 68 ukuran pendorong kualitatif dan kuantitatif ketahanan pangan yang terkelompok menjadi 4 empat pilar utama: keterjangkauan, ketersediaan, kualitas dan

keamanan, serta keberlanjutan dan adaptasi pangan. Hasil index dari seluruh negara dirangkum pada *Global Food Score Index* (GFSI) yang memiliki rentang *score* 0 – 100, dimana *score* 0 absolut tidak tahan pangan dan *score* 100 absolut tahan pangan dari suatu negara.



Gambar 3 Peta GFSI 2022

Berdasarkan data GFSI tahun 2022, rata-rata nilai GFSI adalah 62.2 dengan standar deviasi 12.63 dan median 63.0 dan nilai tertinggi diperoleh oleh Finlandia dengan score 83.7 dan terendah diperoleh oleh Syria dengan score 36.3.



Gambar 4 Peta GFSI 2022

Berdasarkan gambar 4, persebaran data dari GFSI lebih condong ke arah right-skewed dengan persebaran tertinggi berada kelas 60 – 80.



Gambar 5 Score GFSI Indonesia Tahun 2018 – 2022

Score Indonesia pada tahun 2018 – 2022 berada pada kisaran 59.8 – 63.4 dengan rata-rata perubahan Indonesia secara rata-rata perubahan score setiap tahunnya sebesar 1.1 point. Berdasarkan golongan index yang dikeluarkan oleh GFSI, rentang GFSI Indonesia masuk rentang negara dengan tingkat ketahanan pangan moderate dengan rentang kelas pada (55 – 69.9).

4.1.2. Korelasi Faktor-Faktor Pangan terhadap GFSI


Tabel 8 Korelasi beberapa faktor pangan terhadap GFSI

Correlation	Luas Panen (ha)	Produksi (ton)	Import Beras (ton)	Konsumsi Beras/Kapitas/Tahun (kg)	GFSI
GFSI	0.94	0.79	0.73	0.24	1.00

Korelasi merupakan nilai korelasi antar *attributes* pada sebuah *dataset*, korelasi ini dihitung dengan menggunakan metode *pearson* atau disebut juga *standard correlation* yang mengukur tingkat hubungan linier antara dua *attributes* dengan range nilai -1 – 1. Dimana 1 merupakan berkorelasi penuh berbanding lurus, -1 merupakan berkorelasi penuh berkebalikan, dan 0 sama sekali tidak berkorelasi.

Berdarkan data korelasi attribute terhadap GFSI score. 3 atribut yang sangat besar berpengaruh terhadap skor ketahanan pangan suatu negara adalah besarnya luas panen, produksi dalam negeri dan import beras yang dilakukan dengan nilai masing – masing korelasi adalah 0.94, 0.79, dan 0.73. Seluruh faktor pangan berbanding lurus dengan score GFSI dan 3 *attributes* tertinggi memiliki nilai korelasi > 0.70.

4.1.3. Visualisasi Hubungan faktor-faktor Pangan Terhadap GFSI



Gambar 6 Dashboard Hubungan Beberapa Faktor Pangan Terhadap GFSI

Berdasarkan *dashboard* diatas dapat kita lihat bahwa *score* GFSI Indonesia mengalami fluktuasi yang tidak signifikan berada pada kisaran rentang nilai 50 – 65. Sedangkan luas panen pertanian Indonesia mengalami penurunan dari tahun 2018-2021 966,133.22 ha dengan sedikit peningkatan pada tahun 2021-2022 sebesar 194,172 ha, pola yang cukup mirip dimiliki oleh GFSI *score* dimana terjadi penurunan yang *score* GFSI pada tahun 2019-2021.

Jumlah *import* beras Indonesia mengalami fluktuasi yang cukup signifikan dengan penurunan yang signifikan dari tahun 2018-2021 dari sebanyak 2,253,824.4 ton menjadi 407,741.4 ton. Penurunan *score* menunjukkan kemandirian produksi dalam negeri. Namun berdasarkan hasil prediksi kembali terjadi peningkatan *import* beras ke angka 998, 648.6 ton pada tahun 2022. *Import* beras memiliki *trend* yang sama dengan GFSI Indonesia dimana terjadi fluktuasi yang tidak begitu signifikan setiap tahunnya, sehingga claim korelasi dapat diasumsikan sesuai dengan data yang ada.


Konsumsi Beras/Kapita/Tahun (kg) Indonesia ditandai dengan peningkatan yang sangat tajam dari tahun 2019 ke 2020 dari sebesar 94.02 kg/Kapita/Tahun ke 100.9 kg/Kapita/Tahun namun kembali mengalami pelandaian ke angka 92.93kg/Kapita/Tahun. Konsumsi memiliki korelasi paling

rendah terhadap GFSI, sehingga diasumsikan bahwa konsumsi beras/kapita/tahun tidak secara signifikan berpengaruh terhadap score GFSI Indonesia.

Produksi beras Indonesia dengan *trend* penurunan yang dari tahun 2018-2021 dari sebanyak 59,200,533.72 ton menjadi 54,415,294.22 ton, lalu diikuti peningkatan produks dari 2021-2022 ke angka 55,670,219 ton. Berdasarkan tingkat korelasi, produksi beras Indonesia merupakan faktor pangan yang memiliki korelasi linear kedua tertinggi terhadap GFSI.

Berdasarkan data-data pendukung pangan diatas, hal yang dapat kita kontrol adalah dengan meningkatkan luas panen dan tingkat produksi beras dalam negeri sehingga diharapkan mampu untuk mendongkrak GFSI Indonesia ke kelas “good” dengan rentang (70-79.9)

4.1.4. Serangan OPT Padi terhadap Jumlah Produksi Beras




Gambar 7 Perkiraan Kehilangan Hasil Akibat Serangan OPT Utama pada Tanaman Padi [6]

Berdasarkan data yang direktorat perlindungan tanaman pangan kementerian pangan Indonesia pada tahun 2020. serangan OPT Utama pada tanaman padi tahun 2020 sebesar 411.874 ha dengan jumlah puso/gagal berjumlah 7.474 ha. Perkiraan total produksi gagal akibat serangan OPT adalah 74.202.795 ton [6]. Penyakit pada padi dapat dikenali dari perubahan fisik pada permukaan daun. Namun, seiring perkembangan gejala, menjadi sulit untuk membedakan penyakit tanaman

4.2. Data Preprocessing

4.2.1. Dataset

Data penelitian yang digunakan pada penelitian ini adalah beberapa gambar daun tanaman padi yang terbagi menjadi 4 kelas yaitu *Healthy*, *Leaf Smut*, *Bacterial Leaf blight*, *Brown Spot*. Gambar ini digunakan sebagai data untuk melatih model dalam membedakan gambar mana yang merupakan daun padi yang sehat dan yang terkena penyakit.



Gambar 8 jumlah data di setiap kelas

Jumlah data yang digunakan adalah 523 *Healthy*, 432 *Leaf smut*, 422 *Bacterial leaf blight*, dan 431 *Brown spot*. Model akan dilatih dengan rasio 80:20 dimana *data training* 80% dan *data test* 20%. Sampel gambar penyakit pada daun padi dapat dilihat pada Gambar 1.


Sebelum dilakukan training, data terlebih dahulu melalui proses *preprocessing*. Dengan melakukan *split* dengan rasio 80% data latih dan 20% data uji dengan *random state* sebesar 32. Sebelum data di-split akan melalui proses *augmentation* untuk memperkaya *dataset* yang akan digunakan dengan jumlah data setelah *augmentation* sebesar 1808 data.

4.3. Model Training

4.3.1 Arsitektur Model

Penelitian ini menerapkan metode *transfer learning* dengan menggunakan *pre-trained model DenseNet121*. Model ini digunakan

karena telah terbukti mampu mendeteksi penyakit tanaman dengan akurasi ROC AUC sebesar 0.972 [25]. Layers yang ada pada DenseNet121 dijelaskan pada Gambar x.



Gambar 9 Sampel gambar daun padi

Pada penelitian ini menambahkan 4 arsitektur *fully connected layers* dengan *layers* tersebut diantaranya (1) *Dense Layer 1024*, activation ‘*relu*’, *dropout* = 0.2; (2) *Dense Layer 512*, activation ‘*relu*’, *dropout* = 0.2; (3) *Dense Layer 256*, activation ‘*relu*’, *dropout* = 0.2; (4) *Dense Layer 128*, activation ‘*relu*’, *dropout* = 0.2, *flatten*. Sehingga layers dapat divisualisasikan sebagai berikut:

Dense Net121	Input	(240, 240, 3)
	Output	(None, 1024)

↓




Gambar 10 Arsitektur *Model Deep Learning* Menggunakan *DenseNet121* dengan *4 Fully Connected Neural Networks*

Dropout digunakan untuk menurunkan peluang untuk *overfitting* [26]. *Optimizer* yang digunakan adalah *adam*, *Optimizer* ‘*adam*’ merupakan salah satu teknik optimizer yang digunakan untuk memperbarui bobot pada model [26]. Sedangkan, fungsi *loss* yang digunakan adalah *categorical_crossentropy* untuk menerapkan teknik meminimalisir *loss* dan meningkatkan akurasi model [27]

4.3.2 Training Model


Pada penelitian ini model di evaluasi menggunakan *metrics* akurasi dan *f1-score* untuk melihat performansi dari model yang telah dibuat. *Metrics* akurasi menunjukkan seberapa banyak sebuah model memprediksi kelas dengan benar dan *f1-score* menunjukkan kombinasi jumlah benar pada kelas *predicted positive* dan *actual positive* pada *confusion matrix*. Pada

penelitian ini akan digunakan 50 *epoch* sebagai jumlah iterasi train *dataset* dan 64 *batch training sample* diambil dalam setiap iterasinya.



Gambar 11 Grafik model accuracy train dan test terhadap epoch (iterasi ke-)

Gambar 11 menunjukkan grafik *training & validation accuracy* setelah setiap iterasi dilakukan. Sumbu x merepresentasikan jumlah iterasi pelatihan yang telah dilakukan (*epoch*) dengan nilai minimum sebesar 0 dan maksimum sebesar 50. Sumbu y merepresentasikan akurasi model dengan nilai rentang sebesar 0 - 1. Berdasarkan gambar diatas nilai akurasi pada epoch-1 model validasi pada kisaran 0.35 dan telah mencapai akurasi 1 pada \pm epoch-15. Sedangkan model training memiliki akurasi sekitar 0.5 pada epoch-1 dan mencapai akurasi 1 pada \pm epoch-13.



Gambar 12 Grafik model loss train dan validation terhadap epoch (iterasi ke-)

Gambar 12 menunjukkan grafik *training & validation loss* setelah setiap iterasi dilakukan. Sumbu x merepresentasikan jumlah iterasi pelatihan yang telah dilakukan (*epoch*) dengan nilai minimum sebesar 0 dan maksimum sebesar 50. Sumbu y merepresentasikan *loss model* dengan nilai rentang sebesar 0 – 1.4. Berdasarkan gambar diatas nilai *loss* pada epoch-1 pada kisaran 1.4 dan telah mencapai loss 0 pada \pm epoch-35. Sedangkan model training memiliki akurasi sekitar 1.3 pada epoch-1 dan mencapai loss 0 pada \pm epoch-20.

4.4. Model Testing

```


Model Metrics for CNN DenseNet121 Rice Diseases
-----
12/12 [=====] - 1s 106ms/step

```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	84
1	1.00	1.00	1.00	86
2	1.00	1.00	1.00	105
3	1.00	1.00	1.00	87
micro avg	1.00	1.00	1.00	362
macro avg	1.00	1.00	1.00	362
weighted avg	1.00	1.00	1.00	362
samples avg	1.00	1.00	1.00	362

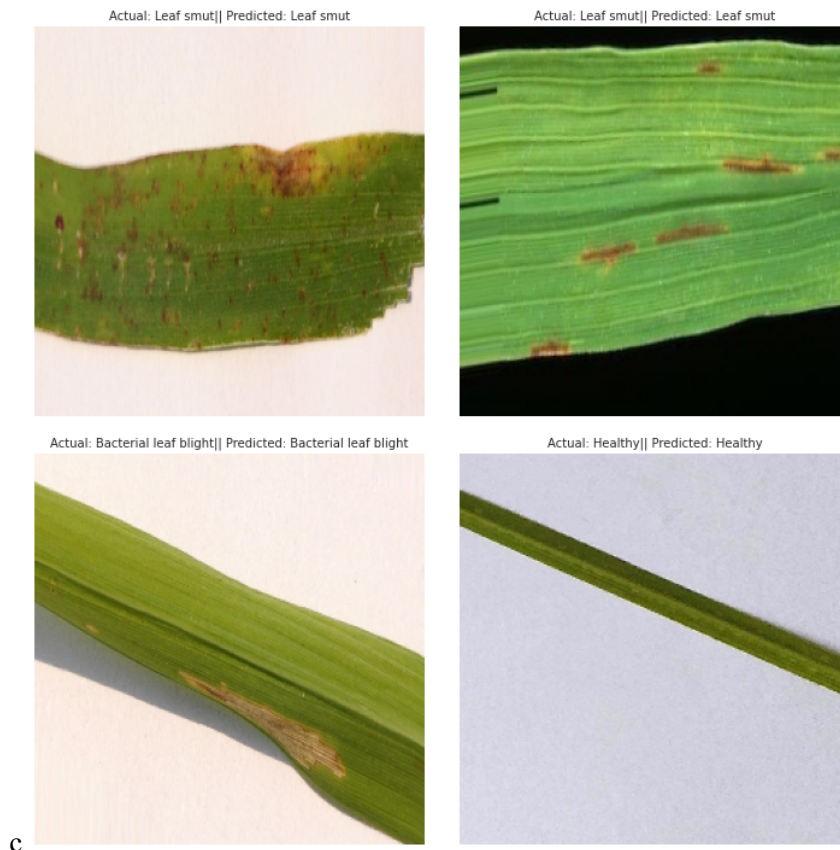
Gambar 13 *Classification Report Train Test Data.*

Berdasarkan *classification report* nilai *f1-score* pada model sebesar 1.00 dengan seluruh variasi *f1-score macro, weighted, dan samples avg* menunjukan nilai 1,00 dengan jumlah *support* sebesar 362 data



Gambar 14 Contoh beberapa klasifikasi records

Bedasarkan data gambar klasifikasi yang dilakukan sesuai dengan klaim yang diberikan dengan tingkat akurasi sebesar 1.0.



Gambar 15 Hasil prediksi data test

Selain itu model testing yang digunakan dengan memberikan gambar random dari *google.images.com* yang telah memiliki label yang pasti, lalu di-*feed* ke model dan diprediksi. Hasil yang diberikan dengan dua *images* adalah sebagai berikut:



Gambar 16 Contoh klasifikasi menggunakan gambar random google.images.com

Berdasarkan hasil klasifikasi diatas kita bisa melihat bahwa padi tersebut memiliki brown spot dan hasil yang diprediksi oleh model adalah benar brown spot

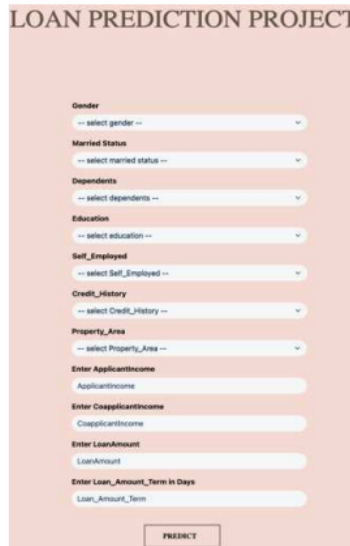
4.5. *Web Deployment*

Model machine learning akan di-deploy secara lokal pada aplikasi berbasis website. Link dapat diakses pada folder /sds/sdsds/sds.html Berikut adalah contoh penggunaan deployment dari model



Halaman beranda situs web digambarkan pada gambar di atas. 8. Terdiri dari tombol PREDIKSI. Setelah mengklik tombol itu, tombol itu

pindah ke halaman berikutnya dari aplikasi web kami. dalam gambar. 9, kita dapat melihat bahwa semua atribut ditampilkan dalam bentuk formulir. Atribut ini perlu diisi. Menurut nilai yang diberikan, kasus Pinjaman disetujui atau Pinjaman ditolak akan ditampilkan.



The screenshot shows a web form titled "LOAN PREDICTION PROJECT". It contains several dropdown menus and text input fields. The dropdown menus are for Gender, Married Status, Dependents, Education, Self_Employed, Credit_History, Property_Area, and Loan_Amount_Term. The text input fields are for ApplicantIncome, CoapplicantIncome, and LoanAmount. A "PREDICT" button is located at the bottom right of the form.

Halaman ini merupakan halaman prediksi, pengguna akan diminta untuk memasukan gambar pada attributes <A>. Setelah gambar sudah dipastikan terupload selanjutnya klik tombol predict untuk mengetahui penyakit dari padi



The screenshot shows the same web form as before, but now it displays the results of a loan prediction. At the top, it says "Your Loan has been Approved". The dropdown menus and text input fields now contain specific values: Gender (Male), Married Status (Yes), Dependents (1), Education (Graduate), Self_Employed (Yes), Credit_History (1.000000), Property_Area (Urban), ApplicantIncome (100000), CoapplicantIncome (16000), LoanAmount (10000), and Loan_Amount_Term (180). The "PREDICT" button is still at the bottom right.

Halaman berikut merupakan halaman solusi yang bisa digunakan pengguna, pengguna yang ingin mengetahui hal-hal yang harus dilakukan sehingga dapat mengembalikan kondisi tanaman menjadi sehat dan atau

mengurangi dampak dari penyakit pada tanaman sehingga dapat tetap menjaga kualitas dari output atau menghindari puso.

5. Kesimpulan

Kombinasi *deep learning pretrained model DenseNet121* dengan *neural networks fully connected layers* (1) *Dense Layer 1024, activation 'relu',* (2) *dropout = 0.2;* (3) *Dense Layer 512, activation 'relu',* (4) *dropout = 0.2;* (5) *Dense Layer 256, activation 'relu',* (5) *dropout = 0.2;* (6) *Dense Layer 128, activation 'relu',* (7) *dropout = 0.2,* (8) *flatten* mampu menunjukkan kemampuan sempurna dalam mengklasifikasi penyakit padi dari 4 kelas (*healthy* (tanpa penyakit), *brown spot*, *hispa*, dan *leaf blast*) dengan nilai f1-score sebesar 1.00 atau 100%. Kedepannya penelitian lanjutan dari penelitian ini adalah dengan peningkatan jumlah kelas dengan resolusi gambar yang berbeda sehingga dapat mencerminkan kondisi lapangan yang bervariasi secara kelas penyakit padi dan variasi data input.

Referensi

- [1] S. E. Rahayu, M. Pohan, H. F. Perekonomian Indonesia. Medan: Perdana Publishing. 2016.
- [2] H.Febriaty, "Analisis Perkembangan Impor Beras Di Indonesia", EKONOMIKAWAN: Jurnal Ilmu Ekonomi dan Studi Pembangunan, 16(2), pp. 134–141. 2016.
- [3] M. A. P. Hutabarat, M. Julham, and A. Wanto, "Penerapan Algoritma Backpropagation Dalam Memprediksi Produksi Tanaman Padi Sawah Menurut Kabupaten/Kota di Sumatera Utara," Jurnal semanTIK, vol. 4, no. 1, pp. 77–86, 2018.
- [4] H. B. Prajapati, J. P. Shah, and V. K. Dabhi, "Detection and classification of rice plant diseases", Intell. Decis. Technol., vol. 11, no. 3, pp. 357–373, 2017.
- [5] I. Y. Purbasari, B. Rahmat, and C. S. Putra PN, "Detection of Rice Plant Diseases using Convolutional Neural Network", IOP Conference Series: Materials Science and Engineering, vol. 1125, no. 1, p. 012021, 2021.
- [6] A. Purwoko. (2021, Agustus. 31). Sukses Kendalikan OPT Padi, Kehilangan Hasil Padi 2020 Hanya 0,7% [Online]. Available: <http://ditlin.tanamanpangan.pertanian.go.id/index.php/iptek/20>.
- [7] E. Anggiratih, S. Siswanti, S. K. Octaviani, and A. Sari, "Klasifikasi Penyakit Tanaman Padi Menggunakan Model Deep Learning Efficientnet B3 dengan Transfer Learning", Jurnal Ilmiah SINUS, vol. 19, no. 1, p. 75, 2021.
- [8] A. T. R. Dazaky, W. F Al Maki, "Deteksi Penyakit Tanaman Cabai Menggunakan Metode Convolutional Neural Network", eProceedings of Engineering, vol. 8, no. 2, 2021.

- [9] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," *Proceedings -30th IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2017*, vol. 2017-January, pp. 2261–2269, 2017.
- [10] S. M. Hassan and A. K. Maji, "Plant Disease Identification Using a Novel Convolutional Neural Network," *IEEE Access*, vol. 10, pp. 5390–5401, 2022.
- [11] F. Masykur, M. B. Setyawan, and K. Winangun, "Optimalisasi Epoch Pada Klasifikasi Citra Daun Tanaman Padi Menggunakan Convolutional Neural Network (CNN) MobileNet Epoch Optimization on Rice Leaf Image Classification Using Convolutional Neural Network (CNN) MobileNet," no. July, pp. 581–590, 2022.
- [12] E. Anggiratih, S. Siswanti, S. K. Octaviani, and A. Sari, "Klasifikasi Penyakit Tanaman Padi Menggunakan Model Deep Learning Efficientnet B3 dengan Transfer Learning", *J. Ilm. SINUS*, vol. 19, no. 1, pp. 75–83, 2021.
- [13] R. A. Saputra, S. Wasyianti, A. Supriyatna, and D. F. Saefudin, "Penerapan Algoritma Convolutional Neural Network Dan Arsitektur MobileNet Pada Aplikasi Deteksi Penyakit Daun Padi", *J. SWABUMI*, vol. 9, no. 2, 2021.
- [14] R. N. Whidhiasi and I. Ekawati, "Identifikasi Jenis Penyakit Daun Padi Menggunakan Adaptif Neuro Fuzzy Inferensi Berdasarkan Tekstur", in *PROSIDING SEMINAR NASIONAL ENERGI & TEKNOLOGI (SINERGI)*, 2019, pp. 131–140.
- [15] S. Agustiani, Y. T. Arifin, A. Junaidi, S. K. Wildah, and A. Mustopa, "Klasifikasi Penyakit Daun Padi menggunakan Random Forest dan Color Histogram", *J. Komputasi*, vol. 10, no. 1, pp. 65–74, 2022.
- [16] Herwina, Darmatasia, A. K. Ash Shiddiq, T. Dzirkullah, Syahputra, "Deteksi Penyakit pada Tanaman Padi Menggunakan MobileNet Transfer Learning Berbasis Android", *Journal of Artificial Intelligence & Data Science*, Volume 2, No. 2, 2022.
- [17] P. Sitompul, H. Okprana, A. Prasetio, "Penyakit Tanaman Padi Melalui Citra Daun Menggunakan DenseNet 201", *Journal of Machine Learning and Artificial Intelligence*, vol. 1, no. 2, 2022
- [18] M. A. Rizaty. (2022, Oct. 14). Indeks Ketahanan Pangan Indonesia Meningkat pada 2022 [Online]. Available: <https://dataindonesia.id/ragam/detail/indeks-ketahanan-pangan-nasional-meningkat-pada-2022>.
- [19] [Badan Pusat Statistik, "Luas Panen, Produksi, dan Produktivitas Padi Menurut Provinsi 2020-2022", <https://www.bps.go.id/indicator/53/1498/1/luas-panen-produksi-dan-produktivitas-padi-menurut-provinsi.html>.
- [20] Badan Pusat Statistik, "Impor Beras Menurut Negara Asal Utama, 2000-2021", <https://www.bps.go.id/statistable/2014/09/08/1043/impor-beras-menurut-negara-asal-utama-2000-2021.html>.
- [21] Pusat Data dan Sistem Informasi Pertanian Sekretariat Jendral, "Buletin Konsumsi Pangan Tahun 2021", *Buletin Konsumsi Pangan*, Vol 12 No 1, 2021.
- [22] JONATHANPEREIRA, 2019, "Rice Disease", Kaggle Dataset.
- [23] MD. SABBIR AHMED, 2020, "paddy-leaf-disease-UCI", Kaggle Dataset.
- [24] Corteva Agriscience, (2022, September. 20) "Global Food Security", *Economist Impact*, <https://impact.economist.com/sustainability/project/food-security-index/download-the-index>.

- [25] D. Orsenigo, C. Moroni, dan P. Monticone, "Dataset Analysis and CNN Models Optimization for Plant Disease Classification".
- [26] C. R. Rahman , P. S. Arko, M. E. Ali, M. A. Iqbal Khan, S. H. Apon, F. Nowrin, A. Wasif, "Identification and recognition of rice diseases and pests using convolutional neural networks", Biosystem Engineering, Vol 194, pp 112-120, 2020.
- [27] M. Kalai Priya, S. Dhanabal, "Analyses of Nine Different Types of Diseases in Paddy with Hybrid Algorithms using Deep Learning", International Journal of Engineering Research & Technology (IJERT), Vol. 8, No. 08, 2020.